



Vector Store & Feature Store

AICB-P2T2 · Ngày 19 · Chương 4: Hạ Tầng

Phạm Mạnh


VinUniversity · Phase 2 · Track 2 · Tuần 4

1. Vector Embeddings: Text -> Số
2. Vector DB Landscape
3. ANN & Retrieval Patterns (HNSW, Hybrid)
4. RAG Pipeline với Vector Store
5. GraphRAG & Knowledge Graphs
6. Feature Store

Sau buổi học này, bạn sẽ:


1. Hiểu vector embeddings và cách ánh xạ text thành dense vectors
2. Deploy và query vector database (Qdrant/Weaviate/Pinecone)
3. Xây dựng RAG pipeline hoàn chỉnh với hybrid search
4. Hiểu về Feature Store với offline/online store

Embeddings → Vector DB → ANN + Hybrid → RAG → GraphRAG → Feature Store
→ Production



- text-embedding-3-small: OpenAI, 1536d
- text-embedding-3-large: 3072d, Matryoshka
- bge-m3: BAAI, 1024d, multilingual
- nomic-embed: open-source
- PhoBERT: VN lightweight baseline (xem bảng 2026)

Cosine Similarity — $\frac{\vec{A} \cdot \vec{B}}{|\vec{A}| \times |\vec{B}|}$ — giá trị
0–1, >0.85 = very similar



2013–2019: task-specific embeddings — mỗi domain (NLP, face, audio) train riêng. **2020–2026:** general-purpose foundation embeddings — một model, nhiều use cases, multilingual, multi-modal. Re-index cost cao ⇒ chọn cẩn thận từ đầu.

Model	Dim	ML	MTEB	Cost
text-embedding-3-small	1536	✓	62.3	\$0.02/M
text-embedding-3-large	3072	✓	64.6	\$0.13/M
bge-m3	1024	✓	59.5	self-host
multilingual-e5-large	1024	✓	~64	self-host
nomic-embed-text-v1.5	768	EN	62.4	self-host
PhoBERT	768	VN-only	baseline	self-host

Prod tiếng Việt 2026: bge-m3 (self-host) hoặc

text-embedding-3-large (API). PhoBERT chỉ cho on-device nhẹ.

- text-embedding-3-large dùng MRL — truncatable: 3072d → 256d
- **256d vẫn thắng ada-002 @ 1536d** trên MTEB
- Tiết kiệm RAM/disk 6×, giảm chi phí vector DB
- Áp dụng ngay khi scale > 10M vectors

Lưu ý: Đổi **embedding model** → phải reindex toàn bộ.

Train (index time) và serve (query time) phải dùng cùng model version

$$\cos(\vec{a}, \vec{b}) = (\vec{a} \cdot \vec{b}) / (\|\vec{a}\| \|\vec{b}\|)$$


- Range [-1, 1], angle only
- Default cho text embedding
- OpenAI/BGE/e5 **unit-norm** ->
- **dot = cosine**
- Match metric với pretraining
- objective: sai metric degrade recall 10–20%

$$\vec{a} \cdot \vec{b} = \sum a_i b_i$$

- Bao gồm magnitude
- Nhanh hơn (no division)
- ColBERT, DPR dùng dot

$$d = \sqrt{\sum (a_i - b_i)^2}$$

- CLIP image, wav2vec/audio
- **unit-norm** -> thứ tự xếp hạng (ranking) của cosine similarity, dot product và Euclidean distance là giống nhau



CLIP (OpenAI): text+image, foundational

SigLIP (Google 2024): better zero-shot

jina-clip-v2: multilingual incl. tiếng Việt

voyage-multimodal-3: text+image+table

ImageBind (Meta): 6 modalities

E-commerce visual search: chụp ảnh → tìm sản phẩm (Tiki, Shopee). **Content moderation:** ảnh+caption matching policy. **Video indexing:** TikTok/YouTube tìm clip theo text prompt. **Medical:** X-ray+report đồng embedding cho clinical search.

Feature	Pinecone	Weaviate	Qdrant	pgvector
Hosting	Managed	Self/Cloud	Self/Cloud	Extension
API	REST/gRPC	GraphQL	REST/gRPC	SQL
Multi-modal	×	✓	×	×
Filtering	Metadata	GraphQL	Payload	SQL WHERE
P99 (1M vecs)	8–22 ms	~10 ms	~5 ms	15 ms
Quantization	✓	✓	✓ (binary)	scalar
Best for	Production	Multi-modal	Self-hosted	Have Postgres

Nguồn:


VectorDBBench 2025 · 1M vectors, 768 dims, HNSW index, top-10 query. pgvector+pgvectorscale (Timescale DiskANN).

- Library, *not* a database — C++/Python, no server
- GPU: 1B vectors, top-K < 1 s
- IVF, HNSW, PQ, OPQ, IVF-PQ — cùng một API
- In-memory + on-disk indices
- 2026: vẫn là embedded tier bên trong Milvus, Vespa, pgvector-rs

- **Face recognition:** FaceNet, ArcFace — FaceID, photo search
- **Pinterest visual lens:** CNN feats + FAISS, 2017+
- **RecSys candidate gen:** YouTube/Spotify/TikTok — ~1B vectors
- **Plagiarism / dedup:** Turnitin, news article clustering
- **Audio fingerprinting:** Shazam, Spotify duplicate detection


Deep Metric Learning — Pre-LLM vector retrieval dựa vào triplet loss (FaceNet), contrastive loss, ArcFace angular margin — train embedding sao cho *cosine* (hoặc Euclidean) tách class. Đây là tiền thân của contrastive pretraining hiện đại (CLIP, SigLIP).

(20 phút) Tìm hiểu đặc điểm của các kỹ thuật lập chỉ mục sau:
HNSW, IVF, PQ, OPQ, IVF-PQ



- **Binary stored** (28 MB) + **scalar query** (precise)
- Best of both: cheap storage + high recall
- Recall $\geq 99\%$ với chi phí binary storage

- Qdrant, Weaviate, Pinecone, Milvus: hỗ trợ binary/scalar out-of-the-box
- Bật quantization **trước khi ingest** — không phải sau
- Re-quantize = re-index $\Rightarrow$ blue-green (xem §6)




Reciprocal Rank Fusion — $\text{score}(d) =$

$$\sum_r \frac{1}{k + \text{rank}_r(d)} \quad (k = 60)$$

Rank-only: không cần normalize raw scores giữa BM25 (TF-IDF) và cosine.

- Recall@10: **91% hybrid** vs 78% dense-only
- Latency overhead: **+6 ms** (parallel retrieval)
- Storage: **1.4×** (BM25 inverted index + vector)
- Native: Qdrant, Weaviate, OpenSearch, Elasticsearch, Milvus
- **SPLADE** (sparse GPU): recall > BM25, nhưng cần GPU inference — chọn BM25 cho cost-sensitive



- **Fixed-size:** 512 tokens, baseline, ngắt giữa câu
- **Recursive:** LangChain RecursiveCharacterTextSplitter — tôn trọng câu/đoạn
- **Semantic:** similarity-based, nghỉ tại topic shift — chậm + tốt nhất
- **Hierarchical:** parent (page) + child (paragraph), retrieve child, return parent

- **Chunk size:** 200–500 tokens cho RAG, 1K+ cho long-context
- **Overlap:** 10–20% (~50–100 tokens)
- **Tooling:** LangChain, LlamaIndex, Unstructured.io
- **Vietnamese:** tokenize ở sentence level, không byte-split

Lưu ý: Đo bằng golden set: Recall@k cải thiện đáng kể khi switch fixed → semantic trên benchmarks. Bad chunking = embedding tốt cũng vô dụng.


- ANN search trả về top-100 candidates
- Bi-encoder: query & doc embed **riêng**
- Latency thấp (<20 ms), recall cao

- ms-marco-MiniLM-L-6-v2: nhẹ, nhanh
- bge-reranker-v2-m3: multilingual, chính xác
- Cohere Rerank API: managed service

- Cross-encoder: query + doc **cùng lúc**
- Score relevance từng cặp (query, doc)
- Chọn top-10 chất lượng cao nhất

- **Self-host:** sentence-transformers trên GPU
— kiểm soát, tiết kiệm ở scale lớn
- **API:** OpenAI text-embedding-3-small,
Cohere embed v4 + Rerank 3.5 — đơn giản,
triển khai nhanh


Vector RAG (chunks)



Top-K nearest chunks
(cosine similarity)

“Ai ở PayPal từng cộng tác với người được Mahle thuê?” — Vector trả về chunks về **PayPal** HOẶC **Mahle** riêng lẻ; không thể **cross-document multi-hop**. KG traverse 3-hop trong μs .

GraphRAG (entity-relation)



Multi-hop: PayPal $\rightarrow$ Alice $\rightarrow$
Project X $\rightarrow$ Bob $\rightarrow$ Mahle

- **P3C diabetes copilot** (Memgraph): patient journey + drug interactions
- **Alzheimer research**: 1.6M edges nối genes-drugs-trials
- **M&A intel** (GlassDollar/Siemens, Mahle): entity search across millions of companies

F


Vector RAG = “đoạn văn liên quan”. GraphRAG = “mối quan hệ kết nối nhiều entity” — chọn graph khi câu trả lời là một **relationship**, không phải đoạn text.





- **Microsoft GraphRAG:** end-to-end + community summaries (LLM-heavy, cost cao)
- **LightRAG:** dual-level retrieval, graph-enhanced indexing, rẻ hơn MS GraphRAG
- **Neo4j + LangChain:** managed graph DB + Cypher query
- **Memgraph:** in-memory graph, sub-ms traversal (P3C copilot)

1. **Start:** vector RAG cho conversational grounding
2. **Add KG:** cho entity-rich domain (legal, medical, M&A)
3. **Hybrid:** vector retrieve → KG expand entities → LLM
4. **Cost:** KG construction = 5–20× vector indexing

Lưu ý: Cost reality: LLM-driven NER + relation extraction cho 100K docs ~\$5K–\$20K (GPT-4o). Bắt đầu nhỏ: 1 domain, 1K docs, validate retrieval lift trước khi scale.







(20 phút): Mỗi nhóm chọn 1 chủ đề để trình bày:

1. Đặc điểm của Online và Offline Store
2. Đặc điểm của Feature View, Feature Service
3. Đặc điểm của Point-in-time & Training-Serving Skew

- Parquet trên S3 / Delta / Iceberg
- Snowflake / BigQuery / Redshift
- **Workload:** historical batch, 100GB–TB
- **Latency:** seconds–minutes (OK for training)
- Lưu *full history* của mọi feature value

- Redis / DynamoDB / Cassandra / Aerospike
- **Workload:** per-entity KV lookup
- **Latency:** <10 ms P99
- Lưu *current value only* (no history)
- Feast `materialize()` nạp offline → online

Point-in-Time (PIT) Join — Khi build training set: lấy feature *as-of timestamp* của mỗi event — không dùng giá trị tương lai. Feast `get_historical_features(entity_df)` thực hiện PIT join trên offline store. **Sai lầm:** dùng LATEST value $\Rightarrow$ data leakage $\Rightarrow$ prod accuracy thấp hơn training 20–30%.

Feature tính **khác nhau** giữa training và serving dẫn đến model hoạt động kém khi deploy mà không có lỗi rõ ràng.

- **Training:** `pd.DataFrame.mean()` trên toàn bộ dữ liệu lịch sử
- **Serving:** `running_mean(last_N)` chỉ N bản ghi gần nhất
- ⇒ Giá trị khác nhau, model sai lệch

- **Training:** parse datetime UTC
- **Serving:** parse local timezone
- ⇒ Feature “giờ trong ngày” lệch 7h (VN)

Lưu ý: Feature Store giải quyết skew: **một định nghĩa duy nhất** dùng cho cả training lẫn inference — không code riêng.

ML Era (2015–2022)

- **Vector store role:** candidate generation cho recsys; retrieval cho face / image search
- **Embeddings:** task-specific (FaceNet, two-tower recsys, doc2vec); train per-app
- **Index tooling:** FAISS / Annoy / NMSLIB embedded trong app process
- **Feature store:** tabular features (counts, ratios, lags) cho XGBoost / DNN tabular
- **Freshness:** daily / hourly batch là mặc định; streaming chỉ cho fraud

LLM Era (2023–2026)

- **Vector store role:** RAG retrieval, agent memory, semantic cache
- **Embeddings:** foundation models (OpenAI, BGE, Voyage); một model nhiều use case
- **Index tooling:** managed multi-tenant (Pinecone, Zilliz Cloud, Vertex Vector)
- **Feature store:** tabular *plus* embedding views; on-demand transforms cho prompt context
- **Freshness:** sub-second streaming là baseline cho fraud, pricing, real-time recsys

Những ý chính cần nhớ trước khi sang bài tiếp theo

- 1 Hybrid Search (BM25 + Vector + RRF, $k = 60$): **91% recall** vs 78% dense-only — production default 2026.
- 2 GraphRAG khi câu trả lời là **relationship** (multi-hop, cross-document), không phải đoạn text. Kiến trúc layered: vector $\rightarrow$ KG.
- 3 Feature Store thẳng cùng lúc **3 dimensions**: feature reuse, train/serve consistency, low-latency online lookup — không tool nào khác giải quyết cả 3.

Ngày 20: Model Serving & Inference Optimization

“Model accuracy 95% nhưng latency 3 giây — user đợi không nổi. Quiz + Milestone 1.”

- Hoàn thành Lab 19: Vector & Feature Store
- Đọc trước: vLLM docs —
- PagedAttention paper
- Ôn tập Chương 4 cho Quiz N20

Hỏi & Đáp

Câu hỏi về Vector DB, Hybrid Search, GraphRAG, hay Feature Store?



Cảm ơn!

AICB-P2T2 · Ngày 19

Vector Store & Feature Store

lms.vinuni.edu.vn · Slide & template trên LMS