



DPO, ORPO & Alignment — Từ SFT đến Preference Learning

AICB-P2T3 · Ngày 22 · Chương 5 — Fine-tuning & An Toàn

Giảng viên

VinUniversity · Phase 2 · Track 3 · Tuần 5

HÃY SUY NGHĨ...

“RLHF tốn kém — DPO làm được điều tương tự mà không cần reward model?”

Giữ câu hỏi này trong đầu khi học bài hôm nay

1. Tại sao SFT chưa đủ?
2. RLHF — Bức tranh toàn cảnh
3. DPO — Direct Preference Optimization
4. ORPO, SimPO & Alternatives
5. RL comeback — GRPO & RLVR
6. Preference Data & Implementation
7. Constitutional AI & Red-teaming

Tại sao SFT chưa đủ?

SFT dạy “nói gì” — nhưng ai dạy model “nói như thế nào”?

01



Post-training pipeline hiện đại:

1. **SFT**: Dạy model format câu trả lời (instruction following)
2. **Alignment**: Dạy model phân biệt tốt/xấu (helpful, harmless, honest)

Practical framing

SFT dạy model “nói gì”.
DPO/ORPO dạy model “nói **như thế nào**” — concise, helpful, an toàn.

SFT-only output

After Alignment

Over-hedges, verbose

Direct, concise

Generic, không actionable

Actionable, helpful

Refusal quá mức

Balanced safety


Alignment — Quá trình dạy model phân biệt câu trả lời **tốt** vs **xấu** bằng preference data — không phải dạy thêm kiến thức mới.

Kết quả nổi bật:

InstructGPT **1.3B** với RLHF

> GPT-3 **175B** không RLHF

⇒ *Alignment beats scale* (Ouyang et al. 2022)



SFT chỉ thấy "good" → không biết good hơn bad bao nhiêu

SFT (demonstration): “Bắt chước câu này.”

⇒ Học **distribution** của data.

Preference (DPO/RLHF): “Câu A *tốt hơn* câu B.”

⇒ Học **margin** giữa good vs bad.

Information signal

Một preference pair (y_w, y_l) chứa thông tin về **cái gì KHÔNG nên nói** — điều mà SFT data không bao giờ biểu lộ trực tiếp.

Less-is-more, nhưng có giới hạn

LIMA (2023): 1K ví dụ chất lượng cao đủ “khơi” alignment — *Superficial Alignment Hypothesis*.

2024–25 phản biện: scale vẫn lợi theo power-law; **SFT ghi nhớ**, **RL khái quát hoá** (Chu et al. 2025).

Reasoning SFT = cold-start

Distill long-CoT từ model mạnh: **s1** (1K ví dụ, \$50), **LIMO** (817), **R1-Distill** (~800K). “SFT story” lớn nhất 2025 — bộ phóng cho RL.

Lưu ý: Curation = bài toán an toàn: fine-tune trên data hẹp “xấu” (vd. code có lỗ hổng) gây **emergent misalignment** — model lệch chuẩn ở mọi domain (Betley et al. 2025).

Refusal = một hướng — Khả năng từ chối nằm trên một direction tuyến tính — xóa nó (“ablation”) gỡ safety chỉ bằng vài bước. Cách curate/ordering SFT quyết định nó bền hay giòn.

RLHF — Bức tranh toàn cảnh

Hiểu RLHF để thấy tại sao DPO là bước cải tiến

02



Lưu ý: RLHF pipeline phức tạp: **3 models, 3 stages**, nhiều hyperparams $\Rightarrow$ chỉ frontier labs (OpenAI, Anthropic) có đủ resources để dùng.

Analogy

RLHF = **thuê giám khảo chấm điểm**, rồi dùng điểm đó dạy lại model chính. Tốn kém gấp đôi.

3

Models cần
train đồng thời

Cao

PPO instability
reward hacking

\$\$\$\$

Chi phí tổng
(infra + annotators)

Câu hỏi then chốt

Nếu ta có thể **bỏ Reward Model** và train trực tiếp trên preference data thì sao? ⇒
Đó chính là ý tưởng của **DPO**.

Lưu ý: Case study — GPT-4o sycophancy (4/2025):

OpenAI thêm reward thumbs-up/down của user $\Rightarrow$ *lấn át* reward chính chống nịnh $\Rightarrow$ model nịnh quá đà, phải **rollback**. Không eval nào theo dõi sycophancy lúc deploy. = Goodhart kinh điển.

Phổ thuật toán RLHF

PPO (có value) $\leftrightarrow$ **RLOO** / **ReMax** / **REINFORCE++** (bỏ value) $\leftrightarrow$ GRPO/DAPO (group baseline). RLOO: $\sim 50\text{--}70\%$ ít VRAM hơn PPO, 2–3 $\times$ nhanh, nạp 3 model thay vì 4.

RLOO — REINFORCE Leave-One-Out (Cohere 2024): baseline = trung bình reward của $k - 1$ mẫu còn lại $\Rightarrow$ bỏ value model mà vẫn giảm variance.

Khi nào *không* cần RL

GEPA (2025): tiến hoá prompt phản tỉnh, thắng GRPO trung bình ~ 6 điểm với **ít hơn tới 35 $\times$** roll-outs. Lab GPU hạn chế: thử prompt-opt *trước* khi deploy RL.

DPO — Direct Preference Optimization


Bỏ Reward Model, train trực tiếp trên cặp tốt/xấu

DPO (Rafailov et al. 2023)

Key insight: optimal RLHF policy có **closed-form solution**. Vì vậy ta có thể train trực tiếp trên preference data mà **không cần Reward Model**.

Analogy: RLHF = thuê giám khảo chấm điểm rồi dùng điểm đó dạy lại. **DPO = cho model xem trực tiếp cặp tốt/xấu, tự học phân biệt** — bỏ qua giám khảo trung gian.

DPO loss: binary cross-entropy trên log-ratio chosen vs rejected probabilities.



Magic trick


“Closed-form optimal policy” (bước 2) là chìa khóa. Nếu không có nó, ta không thể bỏ Reward Model. DPO chỉ áp dụng được cho objective dạng **KL-regularized RL** — không phải mọi RL setup.

Ký hiệu: π_θ policy train · π_{ref} ref (frozen SFT) · σ sigmoid · β KL weight · r reward ẵ · (y_w, y_l) chosen/rejected · KL = Kullback–Leibler.

DPO loss (final form):

$$\mathcal{L}_{\text{DPO}} = -\log \sigma\left(\beta \log \frac{\pi_\theta(y_w)}{\pi_{\text{ref}}(y_w)} - \beta \log \frac{\pi_\theta(y_l)}{\pi_{\text{ref}}(y_l)}\right)$$

Forward pass qua π_θ và π_{ref} trên (prompt, y_w , y_l).
Không rollout, không PPO clipping. (Rafailov et al. 2023)




DPO advantages

Offline learning (stable)

Ít components: chỉ 1 model + ref

Quality tương đương RLHF trên benchmarks

Lưu ý: Known issues: **length bias** (model học viết dài hơn thay vì tốt hơn), **ref model dependency**, overfitting trên small datasets.



β (KL penalty) — β cao $\Rightarrow$ model bị giữ gần ref model hơn. β thấp $\Rightarrow$ model tự do “rời xa” ref model để optimize preference.

- Bắt đầu $\beta = 0.1$ (default)
- Nếu model quá conservative $\Rightarrow$ giảm xuống 0.05
- Nếu model “quên” kiến thức $\Rightarrow$ tăng lên 0.2

IPO (Azar 2023): fix overfit khi preferences quá *deterministic* (sigmoid bão hoà, β mất tác dụng) — *không phải* length bias (đó là **SimPO**).

Lưu ý: Likelihood displacement (Razin 2024, ICLR'25) — prob của *chosen* **giảm** khi train; khi *chosen* $\approx$ rejected, mass dồn sang token **ngược nghĩa** $\Rightarrow$ unalignment (có thể đẩy refusal 74.4% $\rightarrow$ 33.4%). Fix: **CHES filter**.

Lưu ý: Length hacking — DPO thưởng response dài (nhiều log-prob mass). Học “viết dài” thay vì “viết tốt”.

Lưu ý: Mode collapse / sycophancy — mọi câu mở đầu “Great question!” — over-fit preference style.

Triệu chứng trên TRL logs:

- rewards/chosen **giảm** $\Rightarrow$ likelihood displacement
- rewards/margins âm/co $\Rightarrow$ optimization conflict
- Length tăng $>30\%$ $\Rightarrow$ length hacking

Mitigations

Filter pairs có gap quá nhỏ (**CHES**); dùng **SimPO/IPO**; stop sớm khi rewards/chosen đảo chiều.

ORPO, SimPO & Alternatives

Single-stage alignment — bỏ cả bước SFT riêng biệt

04



Cốt truyện

2022: RLHF nặng, 3 models, PPO unstable.

2023: DPO — toán bỏ được RM.

2024: method nở rộ, mỗi method bỏ thêm *một thứ* (ref model, SFT stage, length bias).

2025: RL trở lại (GRPO/RLVR) — rồi cả họ fix **GRPO** (Dr.GRPO, DAPO, GSPO, CISPO) cùng chống *entropy collapse*.

Lưu ý: Tooling đổi liên tục, nhưng câu hỏi không đổi: “**Ai dạy model phân biệt good vs bad?**” Khi câu trả lời là người → RLHF/DPO. Khi là code/regex → RLVR. Khi là chính model → Self-Rewarding / CAI.

Refs: Ouyang 2022, Rafailov 2023, Hong/Meng/Ethayarajh 2024, Tulu 3 2024, DeepSeek-R1 2025.

Method	RM?	Ref?	Stages	Khi nào dùng?
RLHF (PPO)	Có	Có	3	Frontier labs, max quality
DPO	Không	Có	2	Go-to production alignment
Online DPO	Không	Có	2+	On-policy, beats offline (OAIF '24)
IPO	Không	Có	2	DPO over-fit deterministic prefs
SimPO	Không	Không	2	Length-norm, less VRAM
ORPO	Không	Không	1	Base → aligned 1 stage
KTO	Không	Có	2	Chỉ có thumbs up/down
GRPO	Không	Có	1 RL	Reasoning + RLVR

Quick rules

Có SFT + pref pairs $\Rightarrow$ **DPO**. No SFT $\Rightarrow$ **ORPO**. Chỉ +1/−1 $\Rightarrow$ **KTO**. Math/code $\Rightarrow$ **GRPO+RLVR**.

Lưu ý: DPO vẫn là **baseline tốt nhất** 2025-2026. Chuyển method khác chỉ khi có lý do cụ thể (VRAM, no SFT, reasoning).

SimPO (Meng et al. 2024)

Reference-free — không cần π_{ref} .
Implicit reward = **average log-prob**
của response (length-normalized).
+ Target margin γ trên Bradley-Terry.

Kết quả: +6.4 trên AlpacaEval 2, +7.5
trên Arena-Hard so với DPO (§8.3).
Top SimPO model (Gemma-2-9B-it)
đạt 72.4% LC win-rate.

Khi nào dùng: VRAM hạn chế, length bias là vấn đề lớn.

KTO (Ethayarajh et al. 2024)

Single-signal — không cần preference *pairs*.

Mỗi example chỉ cần label **good/bad**
(+1/−1).

Loss dựa trên *prospect theory*
(Kahneman-Tversky): mô hình loss
aversion.

Lợi thế thực tế: dữ liệu thumbs-
up/down từ production logs dễ thu
thập hơn nhiều so với ranked pairs.

Khi nào dùng: có user feedback ratings từ produc-
tion, không có annotators chuyên dụng.

Truyền thống:



ORPO:



50% VRAM reduction
1 stage thay vì 2
Không cần ref model


- ORPO = **Odds Ratio PO**: thêm log odds-ratio penalty (chosen vs rejected) vào SFT loss — 1 objective, no ref model
- Best case: **base model** → **aligned model in one step**
- Skip SFT stage hoàn toàn

Lưu ý: ORPO trade-off: đơn giản hơn nhưng ít mature hơn DPO. Dùng khi muốn train từ base model và VRAM hạn chế.

GRPO (DeepSeek-R1): next frontier cho reasoning alignment — thay thế PPO bằng group relative policy, không cần RM.

RL comeback — GRPO & RLVR

Năm 2025: RL trở lại cho reasoning, nhưng **không cần reward model**



$$\bar{r} = \frac{1}{G} \sum r_i \text{ (group mean)}$$

Advantage $A_i = (r_i - \bar{r}) / \text{std}(r)$
(không cần value/critic model!)

GRPO — Group Relative Policy Optimization. Lấy trung bình reward của **nhóm G samples** cho cùng prompt làm baseline — thay thế cho value model trong PPO.

- PPO clipping ratio như cũ
- **Bỏ value head** $\Rightarrow$ 50% memory savings
- Dùng cho DeepSeekMath, sau đó DeepSeek-R1 (Jan 2025)

Refs: Shao et al. 2024 (DeepSeekMath); DeepSeek-AI 2025 (R1).

RLVR — Reinforcement Learning from **Verifiable** Rewards. Reward = **kiểm tra programmatic** (math match, unit test, regex). Không có “judge” để hack.

Khi nào RLVR work:

- Math: ground truth trong dataset
- Code: chạy unit tests
- Format: regex / JSON schema
- Tool use: success/error from tool

Lưu ý: RLVR *không* thay preference learning cho subjective tasks. **Bổ sung**, không thay thế.

DeepSeek-R1-Zero (Jan 2025):

- Train **base model** (không SFT cold-start)
- Reward = accuracy + format (rule-based)
- Emergent “Aha!” self-reflection

R1 (full): thêm SFT cold-start nhỏ → readability tốt hơn, math reasoning tương đương.

Hook

2023: “RLHF tốn kém, dùng DPO.” 2025: “RL trở lại cho reasoning — *nhưng không reward model.*”

Task type	Method khuyến nghị
Helpfulness, style, tone	DPO / SimPO
Safety, harmlessness	DPO + CAI
Math word problems	GRPO + RLVR (answer match)
Code generation	GRPO + RLVR (unit tests)
Long-form reasoning	SFT cold-start + GRPO
Tool calling correctness	GRPO + RLVR (tool result)
Multi-turn dialogue	DPO (preference pairs)

Quy tắc đơn giản

Có **ground truth** có thể check programmatic? → **RLVR**.

Chỉ có **judgment** của con người? → **DPO**.

Cả hai? → Stack: SFT → DPO → RLVR (Tulu 3 recipe).

Lưu ý: GRPO không miễn phí: cần generation rollouts ($G \approx 8-64$ samples per prompt) $\Rightarrow 3-4 \times$ thời gian so với DPO. Chỉ dùng khi reasoning task thực sự cần.

Variant	Lab	Sửa gì so với GRPO gốc
Dr.GRPO	Sea AI Lab	Bỏ length & std normalization (nguồn length-bias)
DAPO	ByteDance	Clip-Higher, dynamic sampling, token-level loss, overlong shaping
GSPO	Qwen (Alibaba)	Importance ratio ở sequence-level $\Rightarrow$ ổn định RL cho MoE (Qwen3)
CISPO	MiniMax	Clip <i>trọng số</i> importance-sampling $\Rightarrow$ giữ gradient token hiếm

Entropy collapse — Policy sớm trở nên “quyết đoán” $\Rightarrow$ entropy tụt $\Rightarrow$ ngừng explore $\Rightarrow$ training chững ở vài mode hẹp. Bị chi phối bởi *covariance* giữa log-prob token và thay đổi logit.

Một câu để nhớ

Mọi bản vá GRPO kể từ R1, xét cho cùng, là **một thủ thuật giữ entropy** (giữ khả năng khám phá).

Lưu ý: “Không RM = không hack” là *sai*. RLVR mở bề mặt mới: **verifier-gaming** (model liệt kê đáp án để qua checker) và **spurious rewards** — reward ngẫu nhiên/sai *vẫn* giúp...nhưng chỉ trên **Qwen** (không lặp lại trên Llama/OLMo).

Hệ quả dạy học

RLVR gỡ bề mặt hack của learned-RM, *nhưng* thêm rủi ro: gaming verifier + lệ thuộc artefact base model. Luôn kiểm tra trên ≥ 2 base.

Tranh luận mở: RL có thêm reasoning? — Yue et al.: RL chỉ “khơi” năng lực base, pass@k lớn không tăng.


ProRL (2025): RL kéo dài cải thiện pass@k cả ở bài base sai mọi k .

⇒ *chưa ngã ngũ* — đừng dạy như chân lý.

Preference Data & Implementation

Chuẩn bị dữ liệu preference và chạy DPO với TRL

06



Nguồn dữ liệu:

- **Human annotation:** pairwise comparison UI → JSONL export
- **Synthetic:** GPT-4 judge score, rank, tạo pairs
- Tools: Argilla, Label Studio, Prodigy

Quy mô tham khảo

60K pairs cho good alignment.
Open-source: UltraFeedback (64k), Anthropic HH (160k), OpenHermes (1M).

```
from trl import DPOTrainer, DPOConfig
from transformers import AutoModelForCausalLM
model = AutoModelForCausalLM.from_pretrained(
    "path/to/sft-model")          # + LoRA/PEFT
config = DPOConfig(
    beta=0.1, learning_rate=5e-7,  # lab value (TRL
    default 1e-6)
    max_length=1024, max_prompt_length=512,
)
trainer = DPOTrainer(
    model=model, ref_model=None,  # PEFT: base = ref
    args=config, train_dataset=pref_data,
)
trainer.train()
```


Monitoring healthy training:

- **Chosen rewards:** phải **tăng** qua epochs
- **Rejected rewards:** phải **giảm** qua epochs
- Gap giữa 2 loại nên **widen** dần

`ref_model=None` (PEFT)

Với LoRA/PEFT, TRL tự tắt adapter $\Rightarrow$ dùng **base làm reference**, không nạp model thứ 2. Load `ref_model` tường minh = 2 bản full $\Rightarrow$ **OOM trên T4**. **SimPO** bỏ luôn ref.

Lưu ý: Tokenization: verify
`max_prompt_length + max_length` fit con-
text window. Truncation giảm quality.



Lặp lại 6 vòng (Llama 3)

Llama 3 recipe (Meta 2024):

- Train RM trên human preference + edited responses
- Sinh 10–30 generations / prompt → RM chọn best
- SFT trên best, DPO trên (best vs worst)
- **Lặp 6 vòng** với data mới mỗi vòng

Tulu 3 / 3.1 (AI2, 2024–25)

Open recipe: **SFT** → **DPO** → **RLVR**. RLVR (**Tulu 3** = PPO + value model) thêm +1.7 MATH / +3.3 GSM8K / +1.3 IFEval trên DPO checkpoint. **Tulu 3.1** đổi RLVR PPO → **GRPO**: 8B avg 64.8 → 66.3. (Benchmark: §8.2–8.3.)

Lưu ý: Lesson: one-shot offline DPO underper-

Trong DPO world, RM dùng làm gì?

- **Data filter**: loại bỏ pairs gap quá nhỏ (chosen $\approx$ rejected)
- **Rejection sampling**: chọn best-of-N generations cho SFT next round
- **Best-of-N decoding**: tại inference, sinh N câu, pick best
- **LLM-as-judge backbone**: thay GPT-4 cho eval rẻ hơn

Lưu ý: Đừng nhầm: “Không cần RM cho DPO loss” *không* có nghĩa “Không cần RM ở đâu cả”. RM vẫn ở khắp pipeline — chỉ không trực tiếp trong gradient update.

3 họ RM (2025):

- **Scalar / Bradley-Terry**: Skywork-Reward-V2 (Jul 2025), HelpSteer3 — discriminative, default.
- **Generative / reasoning RM**: model tự critique theo rubric — cho task *không* verify được.
- **Process RM (PRM)**: chấm *từng bước* (PRM800K, Math-Shepherd).

Default

Skywork-Reward-V2-Llama-3.1-8B. Dùng làm filter cho rejection sampling + best-of-N.


Model	Base	SFT	DPO?	Ghi chú
VinaLLaMA-7B-Chat	LLaMA-2-7B	✓	×	VN instruction set; chỉ SFT (paper 2023)
PhoGPT-7B5-Instruct	PhoGPT (VN scratch)	✓	×	70K instructions + 290K chats; no preference stage
PhoGPT-4B-Chat	PhoGPT-4B	✓	×	Smaller chat variant
Vistral-7B-Chat	Mistral-7B	✓	×	Community SFT
SeaLLM-v2/v2.5/v3	Llama-2 / Qwen	✓	✓	DPO with self-generated preference data (DAMO)
Sailor / Sailor2	Qwen 1.5/2.5	✓	✓	DPO + variants (SimPO, LN-DPO, LR-DPO) (Sea AI Lab)

Pattern

VN-first (VinaLLaMA, PhoGPT, Vistral) dừng ở SFT.
SEA-regional (SeaLLM, Sailor) chạy tới DPO. ⇒
Gap cho VN-first DPO-aligned model.

Lưu ý: Lab 22 có thể là DPO-aligned VN model
open-source đầu tiên end-to-end của khóa — pub-
lishable.

Refs: VinaLLaMA 2312.11011 · PhoGPT 2311.02945 · SeaLLM 2312.00738 · Sailor (EMNLP 2024) · Sailor2 2502.12982.



Nguồn dữ liệu VN sẵn có:


- **UltraFeedback-vi**: Sailor dịch bằng NLLB-3.3B — “đủ cho DPO” nhưng không native.
- **SeaLLM self-generated**: prompt SeaLLM-SFT, GPT-4 judge.
- **VMLU / ViGLUE**: có ground truth → dùng làm **RLVR rewards** cho academic knowledge (§8.5).

Cơ hội VN

Chưa có *native* large-scale preference dataset — lab artifact đáng publish.

Constitutional AI & Red-teaming

Tạo preference data tự động và kiểm tra an toàn



CAI — Model critique own outputs vs constitution → self-revise → dùng cặp (original, revised) làm preference data.

Ưu điểm:

- Tạo preference data **không cần human annotators**
- Scalable, consistent
- Dùng cho DPO/ORPO training

RLAIF — Reinforcement Learning from AI Feedback (Lee et al. 2023). Thay human annotators bằng **LLM-as-judge**. Empirically: AI feedback $\approx$ human feedback ở scale, 10× cheaper.

Self-Rewarding LM — (Yuan et al., Meta 2024) Model là chính judge của mình. Lặp: generate $\rightarrow$ self-judge $\rightarrow$ form pairs $\rightarrow$ DPO. Sau 3 vòng, Llama-2-70B beats Claude 2 / Gemini Pro / GPT-4-0613 trên AlpacaEval 2.

Collective Constitutional AI (Anthropic 2024):

- Mời **public input** vào constitution document
- Polis-style consensus elicitation
- Constitution không còn là 16 nguyên tắc do Anthropic viết — mà là tinh thần cộng đồng

Pattern chung

Ai sẽ làm judge? Human (RLHF) $\rightarrow$ AI (RLAIF) $\rightarrow$ Self (Self-Reward) $\rightarrow$ Community (Coll. CAI). Rẻ hơn, scale hơn — nhưng risk bias tăng theo.


- Probe model cho **harmful outputs**
- Findings feed back vào preference dataset
- **Domain-specific**: medical misinformation, legal liability

Automated Tools

Garak: vulnerability scanner

PyRIT (Microsoft): adversarial testing

⇒ Scalable, repeatable



Continuous improvement loop

Deliberative Alignment — (OpenAI, o-series) Model *suy luận* dựa trên một **safety spec** viết sẵn ngay lúc inference. o1 đạt StrongREJECT 0.88 vs GPT-4o 0.37 — khái niệm còn thiếu trong deck cũ.

Rule-Based Rewards (RBR) — (OpenAI) Quy tắc an toàn → *reward term* trong RL, không cần thêm human data. Tách bạch: RBR là phần thưởng; deliberative alignment là model lý luận trên spec.

Constitutional Classifiers — (Anthropic 2025) *Bộ lọc lúc deploy* (khác CAI *training* 2022 dù trùng tên): chặn jailbreak vào/ra. Bản 2025 hạ jailbreak từ 86% xuống 4.4%.

Lưu ý: Đừng nhầm tên: CAI (2022) = phương pháp *train* bằng RLAIIF; Constitutional Classifiers (2025) = *guard* lúc chạy. Hai thứ khác nhau.

Giám sát khi model mạnh hơn người chấm

Weak-to-strong (OpenAI): label yếu vẫn “khơi” được năng lực mạnh.

Debate / prover-verifier games: model tranh luận, bên yếu làm trọng tài.

Lưu ý: Alignment faking (Anthropic + Redwood 2024): model *giả* vờ tuân thủ khi biết đang bị train — tỉ lệ giả vờ tăng tới ~78% dưới RL thật.

Lưu ý: CoT không trung thực: chain-of-thought *không* luôn phản ánh lý do thật — faithfulness ~25% (Claude 3.7) / ~39% (R1). Reasoning hiển thị $\neq$ minh bạch.

Bài học

Deliberative alignment cải thiện an toàn *cùng lúc* CoT vẫn có thể không trung thực — giám sát bằng cách đọc CoT phải rất thận trọng.

Đánh giá Alignment — LLM Benchmarks

Static suites · LLM-as-Judge · Reward Bench · Vietnamese landscape

08

Vấn đề cốt lõi

Aligned response là **open-ended** — không có 1 ground-truth duy nhất:

“*Giúp tôi viết email xin nghỉ phép*” → vô số câu trả lời đều đúng.

Khác hẳn classification (1 nhãn đúng) hay translation (BLEU vs reference).

Proxy vs Target

Cái ta đo (helpfulness 1-5) là **proxy** — không phải target thật.

Target thật: user retention, task completion, brand trust, không gây hại.

Mọi metric chỉ là 1 lát cắt ⇒ **cần nhiều metrics + human feedback.**

Lưu ý: 3 nhóm **benchmark** sẽ xuất hiện trong các slide tiếp theo: **Static suites** (MMLU/GSM8K — đo capability) · **Judge-based suites** (MT-Bench/AlpacaEval — đo response quality) · **Reward Model suites** (RewardBench — đo chính các judges). Không 1 cái nào đủ một mình.

Benchmark	Đo gì	Format	Score	Vì sao quan trọng cho aligned model
MMLU	Kiến thức nền 57 subjects	MCQ 4-choice	0–100%	Có quên kiến thức sau alignment?
GSM8K	Math grade-school	Gen + match #####	0–100%	Chat-tuning có giảm reasoning? (alignment)
MATH	Math thi olympic	Gen + LaTeX match	0–100%	Như GSM8K, harder (~50 chỉ top model)
IFEval	Theo lệnh format	Gen + programmatic	0–100%	Aligned model có nghe “trả lời ≤ 3 câu”?
HumanEval	Code generation	Run unit tests	0–100%	Code aligned có chạy được không?
BBH	Mixed reasoning 23 tasks	MCQ + gen	0–100%	Stress-test đa-nhiệm
TruthfulQA	Truthfulness vs myths	MCQ + gen	0–100%	Có hallucinate “common belief” sai?

Tulu 3 reference

Sau DPO + RLVR (xem §9.2b): **+1.7 MATH · +3.3 GSM8K · +1.3 IFEval** — nhưng MMLU thường *flat* hoặc *giảm* nhẹ sau chat-alignment.

Tất cả đều programmatic scoring; chạy offline trên 1 GPU.

Benchmark	# prompts	Format	Judge	Tradeoff
MT-Bench	80 multi-turn	Score 1–10	GPT-4	Tiny set; judge có position bias
AlpacaEval 2 LC	805 single-turn	Win-rate vs gpt-4-1106	GPT-4	Length-controlled (Dubois 2024) sửa length-bias
Arena-Hard	500 hard prompts	Win-rate vs gpt-4-0314	GPT-4	Khó cho weak models; thậm chí gpt-3.5 cũng <30%
Chatbot Arena	live, >3M votes	ELO ranking	Người dùng thật	Ground-truth nhất, nhưng đắt + chậm

Cross-judge tip

Chạy cùng 1 prompt qua **2 judges khác nhau** (gpt-4o-mini + claude-haiku-4-5); disagreement = signal cần xem tay.

Lưu ý: Length bias (judges thiên vị câu dài) là failure mode lớn nhất pre-2024. AlpacaEval 2 LC fixes nó. **2025:** MT-Bench & AlpacaEval đã *bảo hoà* — chuyển sang **Arena-Hard-v2** (style-controlled); cân trọng *Leaderboard Illusion* của LMArena.

Tại sao cần benchmark cho RM/-judges?

Judge cũng là 1 model $\Rightarrow$ có bias.

RewardBench 2 (AI2 2025): best-of-4, khó hơn v1 ~ 20 điểm, prompt người mới.

RM-Bench: RM top *dưới* mức ngẫu nhiên khi có style bias. **JudgeBench**: GPT-4o $\approx$ random $\Rightarrow$ dùng reasoning-judge.

Tulu 3 dùng **Skywork-Reward** làm *filter* preference data trước DPO.

Lưu ý: Vấn đề recursion: judge cần judge, RM cần benchmark, benchmark cần evaluation — không có “ground truth” tuyệt đối ngoài **con người + thời gian + production data**. Constitutional AI (§7) là 1 cách *thoát recursion*: dùng **explicit rules** làm anchor thay vì preferences.

Trong lab

NB4 = judge-based, NB6 = static — 2 lăng kính khác nhau, kết quả khác nhau là bình thường.

Benchmark	Đo gì	Status	Note
VMLU	10K MCQ, 58 VN subjects	Active 2024+	Pham et al. — “lò luyện thi” THPT + ĐH
ViGLUE	NLU 5 tasks (NER, sentiment, NLI, QA)	2023 stable	Older, vẫn dùng được cho NLU baseline
ViMMLU	MMLU dịch sang Việt	2023	NLLB-MT quality concerns; OK cho rough c
VLSP shared tasks	Various NLP tasks	Annual	Academic; dataset rotates yearly
VN AlpacaEval	Win-rate VN	GAP	Chưa tồn tại! Bonus B opportunity

Lưu ý: Native VN judge-based benchmark chưa tồn tại. Sailor2 dùng UltraFeedback-vi (translated). Cơ hội: ai trong cohort này build 1 *native* VN AlpacaEval-style set 200–500 prompts ⇒ **publishable đầu tiên** (xem BONUS-CHALLENGE.md provocation #1).

Demo & Thực hành

DPO training thực tế + đo improvement bằng GPT-4 Judge

09

1. Lấy SFT checkpoint từ Lab 21, apply DPO với 2k UltraFeedback pairs, 1 epoch
2. Before DPO: over-hedges, generic, verbose. After DPO: direct, concise, actionable
3. GPT-4 judge: helpfulness từ **3.2** → **4.1** out of 5
4. So sánh: chosen rewards tăng, rejected rewards giảm — healthy training signals

3.2 → 4.1

Helpfulness
(GPT-4 judge)

—40%

Response length
(less verbose)

1 epoch

Training time
(~30 min A100)

Tại sao hiệu quả?

DPO dạy model phân biệt **trực tiếp** giữa good vs bad response — model học preference signal rất nhanh, chỉ cần 1–2 epochs.

+1.7

MATH
sau RLVR (vs DPO)

+3.3

GSM8K
sau RLVR

+1.3

IFEval
sau RLVR

Độc bảng số

Tulu 3 publish toàn bộ recipe + data + code. RLVR ở đây = **PPO + value model** (Tulu 3.1 sau đổi sang **GRPO**: 8B avg 64.8→66.3 — A/B công khai sạch nhất). **Cộng dồn**: SFT → DPO → RLVR đủ để Tulu 3-405B vượt Llama 3.1-Instruct-405B và DeepSeek-V3 trên AI2 eval suite.

Mục tiêu: DPO alignment trên SFT checkpoint + deploy aligned model

Deliverable: Aligned model deployed: merge adapter, quantize, serve với vLLM.
Report: SFT-only vs SFT+DPO comparison.

Thời gian: 2 giờ

1. **Prepare preference dataset:** human-ranked response pairs (hoặc synthetic via GPT-4 judge), format prompt/chosen/rejected
2. **Train DPO adapter:** trên SFT checkpoint từ Lab 21 dùng TRL DPOTrainer. Monitor chosen/rejected rewards
3. **Compare:** SFT-only vs SFT+DPO trên safety và helpfulness metrics. Dùng GPT-4 judge cho evaluation
4. **Deploy:** merge adapter, quantize GGUF, serve với vLLM. Measure latency overhead

Deliverable

GitHub repo + comparison report: helpfulness score trước/sau DPO, safety metrics, example outputs

Bonus A

DPO vs ORPO head-to-head

1. Cùng base model, cùng preference data
2. Train 1 adapter DPOTrainer, 1 ORPOTrainer
3. So sánh: judge win-rate + time + VRAM
4. Plot: chosen/rejected reward trajectories

Outcome: hiểu trade-off “đơn giản vs mature”.

Bonus B

Vietnamese preference data

1. 200 prompts từ VN SFT set / VMLU stems
2. 2 responses: Lab21-SFT + stronger (Gemini Flash / Claude Haiku)
3. Judge: GPT-4o / Claude Sonnet (VN-aware prompt)
4. Train DPO 200 pairs, so sánh native vs UltraFeedback-vi

Outcome: dataset + adapter publishable — fill VN gap.

Bức tranh toàn cảnh — Full training flow

Alignment chỉ là một mảnh ghép — xem nó nằm ở đâu trong vòng đời của LLM



Pre-training	Mid-training	Post-training
Trillions of tokens, next-token prediction	Continued pretraining, domain adapt, long-context extension	SFT → DPO → RLVR; merge, distill, optimize
Cost: rất cao (M USD) Frontier labs only	Cost: cao Domain teams	Cost: vừa phải <i>Most ML teams live here</i>

Insight

99% công việc của ML team trong industry rơi vào **post-training** (+ một ít mid-training). Pre-training là sân chơi của 5-10 lab toàn cầu (OpenAI, Anthropic, Google, Meta, Mistral, Alibaba, DeepSeek...).

Lưu ý: Khi nào cần pre-training? Hầu như **không bao giờ** cho startup/enterprise. Default: bắt đầu từ Llama / Qwen / Mistral base + post-train. Pre-training chỉ khi domain thực sự ngoài distribution (vd: protein sequences).

Model (lab)	Các stage post-training	Open?	Điểm nhấn
Llama 3 (Meta)	SFT → rejection-sampling → iterative DPO	một phần	6 vòng DPO
Llama 4 (Meta)	light-SFT → online-RL → <i>light</i> -DPO	một phần	DPO <i>cuối</i> , tối thiểu
Tulu 3 / 3.1 (AI2)	SFT → DPO → RLVR (PPO → GRPO ở 3.1)	full	Recipe + data mở
Qwen3 (Alibaba)	offline + online RL (GSPO)	weights	GSPO ổn định MoE
DeepSeek-R1	cold-start SFT → RL (GRPO)	weights	Pure-RL reasoning

Thông điệp

RL là trung tâm; DPO bị “giáng” xuống bước phụ nhẹ; value model phần lớn biến mất; biên giới chuyển sang **agentic multi-turn RL**.

Lưu ý: Llama 4: “SFT/DPO quá chặt *bóp* không gian explore của online RL” ⇒ làm nhẹ & đặt sau.

Method	Data	Compute	Khi nào dùng?
DAPT (continued pre-training)	Raw domain text (10B+ tokens)	cao	Domain hoàn toàn ngoài distribution (medical, legal, code)
TAPT (task-adaptive PT)	Unlabeled task corpus	vừa	Có sẵn task corpus, label chưa có
SFT / LoRA fine-tune	Labeled instruction pairs	thấp	Đã có format và task rõ ràng
DPO / preference align	Preference pairs	thấp	Behavior alignment, không phải domain knowledge

Sequential recipe

Khi cần cả 2: **DAPT** → **TAPT** → **SFT** → **DPO**. Mỗi bước thêm vài points. (Gururangan et al. 2020 “Don’t Stop Pretraining”.)

Lưu ý: Catastrophic forgetting là rủi ro lớn nhất của DAPT/TAPT. **Replay 50/50**: trộn 50% domain + 50% general (Pile, RedPajama).

1. **Self-Instruct** (Wang 2022): seed prompts, LLM tự sinh thêm. Quality thấp, scale dễ. (Alpaca lineage.)
2. **Evol-Instruct** (WizardLM 2023): lặp prompt rewriting để tăng độ khó (in-depth, in-breadth, deepening).
3. **Persona-driven** (Persona Hub 2024): 1B personas → diverse perspectives trên cùng prompt.
4. **Verified synthesis** (2024+): LLM sinh response, sau đó *kiểm tra programmatic* (chạy code, regex check, tool call result) trước khi đưa vào dataset — vd. WizardCoder, OpenMathInstruct, Tulu-3 RLVR data.

Phi recipe

Phi-3/Phi-4 đặt cược vào synthetic “textbook-like”: structured, step-by-step. **Phi-4 vượt teacher GPT-4 trên STEM** — distillation không còn là trần.

Lưu ý: Pitfalls: mode collapse khi self-generate; license risk khi dùng GPT-4/Claude làm teacher; quality decay sau 2–3 thế hệ synthetic.

Alpaca (2023)	Vicuna/WizardLM (2023)	Orca (2023-24)	Phi-3/Phi-4 (2024-25)
52K Self-Instruct, GPT-3.5 teacher, imitate response	ShareGPT logs, Evol-Instruct, scale up	GPT-4 teacher, copy <i>reasoning traces</i> , step-by-step CoT	Synthetic “textbooks”, curriculum-driven, surpasses teacher on STEM

Tiến hóa của distillation

Gen 1: copy outputs. Gen 2: copy at scale. Gen 3: copy reasoning. Gen 4: synthesize structured curriculum → student *vượt* teacher.

Lưu ý: Legal: OpenAI/Anthropic/Google ToS cấm dùng output để train competing model. Lab/research thường OK; commercial cần legal review. Open alternatives: Llama-3 70B, Qwen-2.5-72B, Mixtral-8x22B teachers — license cho phép commercial distillation.

FlashAttention (v1/v2/v3) — Attention exact, nhưng tile-by-tile, giữ data trong SRAM thay vì HBM. **2–4× speedup**, **$O(N)$** memory thay vì $O(N^2)$. v3 (Hopper H100) thêm async + FP8.

Gradient checkpointing — Không lưu activations trong forward; recompute trong backward. **Trade memory cho compute:** 30–50% memory savings, 30% slower. Bắt buộc cho long-context FT.

Combine cả hai:

- FlashAttn $\Rightarrow$ tăng max sequence length
- Grad ckpt $\Rightarrow$ tăng max batch size
- BF16 mixed precision $\Rightarrow$ 50% memory
- NF4 4-bit $\Rightarrow$ thêm 50%

Order khi OOM

1. Mixed precision $\rightarrow$ 2. Grad ckpt $\rightarrow$ 3. FlashAttn 2 $\rightarrow$ 4. 4-bit (QLoRA) $\rightarrow$ 5. Gradient accumulation $\rightarrow$ 6. ZeRO/FSDP (multi-GPU).

Stage	Shard	Savings	Khi nào dùng?
Stage 0 (DDP)	Replicate everything	1×	1 GPU đủ memory
ZeRO-1	+ Optimizer state	4×	2–4 GPUs cùng node
ZeRO-2	+ Gradients	8×	4–8 GPUs cùng node (default)
ZeRO-3 / FSDP	+ Parameters	N×	Model > single-GPU memory

Quick guide

1 GPU: không cần ZeRO — dùng QLoRA + grad ckpt. **2–8 GPUs:** ZeRO-2 (DeepSpeed) hoặc FSDP. **>8 GPUs / multi-node:** FSDP + selective ckpt; Stage 3 khi cần.

Lưu ý: FSDP gotcha: dùng *non-reentrant* activation checkpointing với FSDP — legacy reentrant variant xung đột với FSDP state sync. Selective activation ckpt (PyTorch 2024+) thêm 10% throughput.

DoRA — Weight-Decomposed LoRA (Liu 2024).
Tách update = **magnitude** + **direction**. Tốt hơn LoRA ở rank thấp.

rsLoRA — Rank-Stabilized (Kalajdzievski 2023).
Scaling $\alpha/\sqrt{r}$ thay vì $\alpha/r \Rightarrow$ stable gradient ở rank cao ($r = 64-128$).

PiSSA — Principal SV Adaptation (NeurIPS 2024).
Init LoRA bằng top-SVD của W_0 thay vì random.
+5.16% trên GSM8K (Mistral-7B).

Decision guide

Default: LoRA $r = 8-16$, $\alpha = 16-32$. **Low rank** ($r \leq 4$): DoRA. **High rank** ($r \geq 32$): rsLoRA.
Convergence nhanh: PiSSA. **VRAM cực hạn:** QLoRA+NF4.

Lưu ý: 2025: với LR tuning đúng, mọi variant peak tương đương vanilla LoRA (Liu 2025). Tune LR trước, đừng over-engineer.

Hỗ trợ trong HuggingFace PEFT ≥ 0.10 .

- **SLERP**: spherical linear interpolation, merge 2 *models* dọc đường cầu giữ angle. Đơn giản, hiệu quả khi 2 models share base.
- **Task Arithmetic**:
$$\theta_{\text{merged}} = \theta_{\text{base}} + \sum_i \lambda_i (\theta_i - \theta_{\text{base}}).$$
Cộng/trừ “task vectors”.
- **TIES** (Trim, Elect Sign, Merge): trim 80% delta nhỏ nhất, vote sign chung → giảm interference.
- **DARE**: drop 90–99% delta ngẫu nhiên rồi rescale. Surprising: vẫn giữ performance.
- **DARE-TIES**: kết hợp 2 method trên cho multi-model merge.

Tooling

mergekit (Arcee AI): toolkit chuẩn de-facto. YAML config, support tất cả methods. `pip install mergekit`.

Use cases

Multi-skill: merge math-FT + code-FT + chat-FT. **Continual learning**: merge base + new-domain FT. **Open LLM Leaderboard**: phần lớn top models 2024 là merges.

Quantization (training-free):

- **NF4** (QLoRA): 4-bit normal-aware — default FT.
- **GPTQ**: post-training 4-bit + calibration set.
- **AWQ**: activation-aware, tốt hơn GPTQ ở 4-bit.
- **GGUF**: format llama.cpp (Q4_K_M...).

Serving:

- **vLLM**: continuous batching, PagedAttention.
- **Speculative decoding**: 2–3× throughput.
- **KV cache quant**: 8/4-bit cho long-context.

Advanced training & mid-training:

- **Long-context** (mid-train): RoPE scaling — NTK, YaRN, LongRoPE → 4K → 128K+.
- **MoE fine-tune**: FT subset experts.
- **Multi-token prediction**: predict n forward.
- **Curriculum learning**: easy-to-hard (Phi-4).
- **Pruning**: SparseGPT, Wanda — ít phổ biến.

Lưu ý: Đừng dùng tất cả cùng lúc. Thêm từng cái, đo, giữ cái work.

1. Có preference pairs?

- ▷ +SFT model → **DPO / SimPO**
- ▷ Không SFT → **ORPO** (1-stage)
- ▷ Chỉ **+1/-1** → **KTO**

2. Có instruction data? → **SFT (LoRA/QLoRA)**, rồi thu preference → DPO.

3. Chỉ raw domain text?

- ▷ Xa base (medical/legal/code) → **DAPT** → **TAPT** → **SFT** → **DPO**.
- ▷ Gần base → skip DAPT, SFT với synthetic data.

4. Math/code/ground truth? → sau DPO thêm **GRPO + RLVR** (Tulu 3).

5. Nhiều task-specific FT models cần combine? → **Model merging** (TIES/DARE/SLERP).

6. Cần deploy efficient? → Quantize (NF4/AWQ/GGUF) + vLLM/llama.cpp + speculative decoding.

Lưu ý: Reality: hầu hết enterprise teams chạy **SFT + DPO** là đủ. Phần còn lại là “nice to have”.

Mở rộng — Inference-time & Multimodal alignment

Hai trục alignment ngoài “train-time, text-only”



Đòn bẫy rẻ

Best-of-N / reward-guided decoding: sinh N, chọn theo RM (DeepSeek-GRM cho thấy scale *lúc inference* có thể sánh scale model-size).

Controlled decoding: lái logits theo reward.

Activation steering — Cộng một vector “hướng” vào activations (CAA) để tăng/giảm hành vi (an toàn, từ chối) — không đụng trọng số.

Lưu ý: Đánh đổi: tốn compute lúc chạy, và RM/steering vẫn có thể bị hack. *Bổ sung*, không thay alignment train-time.

Vì sao tách riêng

Toàn bộ deck là *text-LLM*. VLM (vision-language) có nhánh preference learning riêng: **RLHF-V**, **MM-RLHF**, **OVIP**.

Hallucination = reward target — Với VLM, “verifier” thường là **grounding thị giác**: phạt khi model mô tả vật *không có* trong ảnh $\Rightarrow$ giảm hallucination.

Những ý chính cần nhớ trước khi sang bài tiếp theo

- 1 DPO vẫn là go-to 2025-2026 — nhưng phải **iterative** (Llama 3 / Tulu 3), không one-shot
- 2 Watch failure modes: likelihood displacement, length hacking. rewards/chosen đảo chiều = stop
- 3 ORPO khi base $\rightarrow$ aligned 1 stage; SimPO khi length bias là vấn đề; KTO khi chỉ có +1/-1
- 4 RL là **trung tâm** 2025-26 (GRPO + họ fix chống entropy collapse; Tulu 3.1 PPO $\rightarrow$ GRPO). DPO giáng xuống bước phụ. Stack: SFT $\rightarrow$ DPO $\rightarrow$ RL
- 5 VN-first models dừng ở SFT — Lab 22 Bonus B là cơ hội publish DPO-aligned VN model

Ngày 23: LangGraph & Agentic Orchestration

“Model đã aligned. Tiếp theo: orchestrate complex workflows với LangGraph stateful machines.”

- Hoàn thành Lab 22: DPO alignment + deploy aligned model
- Đọc: LangGraph documentation — State, Nodes, Edges

Hỏi & Đáp

DPO hay ORPO — bạn sẽ chọn method nào cho project của mình và tại sao?



Cảm ơn!

AICB-P2T3 · Ngày 22 · DPO, ORPO & Alignment — Từ SFT đến Preference Learning

github.com/VinUni-AI20k

Liên hệ: instructor@vinuni.edu.vn